

IA PARA DEVS

INTRODUÇÃO AO ALGORITMO GENÉTICO

AULA 02

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	14
REFERÊNCIAS.....	15

EMSE

O QUE VEM POR AÍ?

Nesta aula, entraremos no intrigante universo dos Algoritmos Genéticos, explorando sua base conceitual centrada na "Inspiração da Natureza". Analisaremos como os algoritmos bioinspirados encontram raízes em fenômenos naturais, destacando exemplos como redes neurais e colônias de formigas, com foco especial no algoritmo genético, profundamente vinculado à teoria da evolução.

Vamos entender o que é a teoria da evolução e como, a partir dela, escrevemos as regras que definem os algoritmos genéticos. Utilizaremos um diagrama ilustrando cada passo do Algoritmo Genético. Além disso, exploraremos o histórico e a evolução desses algoritmos, apresentando marcos ao longo do tempo e destacando sucessos na resolução de problemas do mundo real.

A aula também abordará a aplicação dos algoritmos genéticos no treinamento de Redes Neurais, explorando conceitos como neuroevolução e NEAT. Ao final, você terá uma base sólida sobre a inspiração da natureza por trás dos algoritmos genéticos e seu impacto abrangente em diversas áreas.

HANDS ON

Na última aula, abordamos os fundamentos dos algoritmos de otimização, utilizando o “problema do caixeiro viajante” como exemplo. Exploramos tipos de problemas de otimização e discutimos soluções exatas, como métodos analíticos e força bruta, enfatizando sua garantia de resposta ótima. Introduzimos, também, soluções heurísticas, destacando sua eficácia em problemas complexos. Utilizamos a técnica do vizinho mais próximo no contexto do caixeiro viajante para ilustrar como a complexidade cresce exponencialmente com o número de cidades.

Esta segunda aula do nosso curso de Algoritmos Genéticos vai abordar o conceito fundamental de "Inspiração da Natureza". Exploraremos algoritmos que encontram sua origem em fenômenos naturais, destacando redes neurais, colônias de formigas e, especificamente, o algoritmo genético. Este último, profundamente enraizado na teoria da evolução, será desvendado ao explicarmos a teoria da evolução, ilustrando-a com exemplos concretos. A compreensão do princípio de funcionamento do algoritmo genético será facilitada por um paralelo entre a evolução na natureza e a replicação de regras no contexto dos algoritmos genéticos, com um diagrama elucidativo dos passos envolvidos.

Adicionalmente, vamos explorar o "Histórico e Evolução" dos algoritmos genéticos, apresentando uma linha do tempo com seus principais avanços ao longo dos anos. Destacaremos problemas do mundo real que foram abordados com sucesso por meio desses algoritmos. Além disso, examinaremos a aplicação dos algoritmos genéticos no treinamento de Redes Neurais, explorando conceitos como neuroevolução e NEAT. Ao final desta aula, você terá uma compreensão sólida da inspiração na natureza por trás dos algoritmos genéticos e seu impacto significativo em diversas áreas.

SAIBA MAIS

Nesta seção, vamos nos aprofundar no NEAT – “Neuroevolution of Augmented Topologies”. É um algoritmo de neuroevolução que utiliza princípios inspirados na teoria da evolução para treinar redes neurais artificiais. Diferenciando-se de métodos tradicionais, NEAT é distinto por sua capacidade de evoluir arquiteturas de rede neural complexas, incluindo mudanças na topologia da rede ao longo do processo de evolução.

Isso é alcançado por meio da introdução de operadores genéticos especializados, permitindo que novas estruturas de rede sejam criadas e adaptadas ao longo do tempo. Essa abordagem dinâmica e adaptativa torna o NEAT particularmente eficaz em problemas complexos de otimização e aprendizado, além de fornecer insights valiosos sobre a evolução de sistemas neurais biológicos.

Nas próximas seções você verá mais sobre o NEAT, os operadores genéticos específicos desta arquitetura, e as técnicas de balanceamento de aproveitamento e exploração, casos de aplicação prática e quais são as principais considerações e desafios futuros.

NEUROEVOLUTION OF AUGMENTING TOPOLOGIES (NEAT)

O “NeuroEvolution of Augmenting Topologies”, ou simplesmente NEAT, representa uma abordagem inovadora na evolução de redes neurais artificiais. Seu propósito principal reside em superar as limitações das redes neurais fixas, permitindo a adaptação dinâmica da topologia da rede durante o processo de treinamento. Essa flexibilidade promove uma busca mais eficiente por soluções ótimas em ambientes complexos e dinâmicos.

Conforme evidenciado no vídeo sobre o Marl/O, exibido durante a videoaula, a rede neural inicializa com conexões e pesos de maneira aleatória. À medida que progride por meio das gerações de treinamento, a rede neural aprimora suas características, aperfeiçoando-se gradativamente e elevando o valor da função de aptidão de forma contínua. Esse processo iterativo revela a capacidade da rede neural

em aprender e adaptar-se, culminando em um refinamento progressivo que impulsiona seu desempenho ao longo do tempo.

EVOLUÇÃO DE TOPOLOGIAS DINÂMICAS

Uma das características distintivas do NEAT é a capacidade de evoluir topologias de redes neurais de forma dinâmica. Durante o treinamento, o NEAT pode adicionar ou remover conexões e neurônios, ajustando assim a complexidade da rede conforme necessário. Essa capacidade de adaptação permite que o NEAT enfrente desafios variados e explore soluções que redes tradicionais não seriam capazes de alcançar.

Esse comportamento dinâmico torna-se evidente ao acompanhar o processo de treinamento no Marl/O. Ao longo do aprendizado, observamos o surgimento e desaparecimento de conexões, assim como a variação na presença de neurônios nas camadas intermediárias da rede neural. Esse dinamismo reflete a capacidade de adaptação da rede, revelando um processo fluido de ajustes que contribuem para sua evolução durante o treinamento.

OPERADORES GENÉTICOS ESPECÍFICOS DO NEAT

Os operadores genéticos exclusivos do NEAT desempenham um papel fundamental na evolução das redes. A criação e remoção de conexões e neurônios garantem a diversidade genética na população, facilitando a exploração de soluções inovadoras. Essa abordagem genética contribui para a emergência de arquiteturas de redes neurais mais complexas e adaptáveis.

Esses são alguns dos **operadores de crossover e mutação** utilizados no NEAT:

Crossover Estrutural

Permite a troca de material genético entre dois pais, mas com uma abordagem única. Em vez de simplesmente misturar pesos, o crossover estrutural no NEAT pode adicionar ou remover conexões e neurônios, adaptando a topologia da rede.

Exemplo: se dois pais têm diferentes conjuntos de conexões, o crossover estrutural pode resultar em uma prole que combina as conexões de ambos ou introduz novas conexões.

Mutação de Adição de Conexão

Introduz uma nova conexão na rede neural. Isso ajuda a explorar novas possibilidades de representação.

Exemplo: adicionar uma conexão entre neurônios que antes não estavam conectados, criando uma rota alternativa para informações fluírem.

Mutação de Adição de Neurônio

Insere um novo neurônio na rede, dividindo uma conexão existente em duas partes. Isso promove maior modularidade e complexidade.

Exemplo: dividir uma conexão entre dois neurônios existentes, inserindo um novo neurônio no caminho, o que pode permitir uma representação mais sofisticada.

Mutação de Remoção

Remove aleatoriamente uma conexão ou um neurônio da rede, controlando sua complexidade.

Exemplo: eliminar uma conexão que não contribui significativamente para o desempenho ou remover um neurônio redundante.

BALANCEAMENTO ENTRE EXPLORAÇÃO E APROVEITAMENTO

Antes de entender como exploração e aproveitamento são balanceados no NEAT, vamos primeiro rever o que significam esses conceitos em problemas de otimização.

Exploração vs Aproveitamento

A dicotomia entre exploração e aproveitamento é um conceito central em algoritmos de otimização, destacando a necessidade de equilibrar a busca por novas soluções (exploração) e a exploração de soluções conhecidas e promissoras

(aproveitamento). Essa é uma consideração crítica para maximizar a eficácia na busca por soluções ótimas em espaços de busca complexos. Vamos explorar cada conceito.

Exploração: a exploração refere-se à busca por novas soluções em áreas do espaço de busca ainda não exploradas. Isso envolve tentar diferentes abordagens, realizar modificações nas soluções existentes e, em geral, arriscar na esperança de encontrar soluções melhores ou mais inovadoras. A exploração é vital para descobrir regiões desconhecidas do espaço de busca que podem conter soluções mais eficazes.

Aproveitamento: o aproveitamento, por outro lado, consiste em utilizar e aprimorar soluções que já demonstraram ser eficazes. Ao se concentrar nas soluções mais promissoras encontradas até o momento, o algoritmo visa otimizar e refinar essas soluções. O aproveitamento é crucial para extrair o máximo de desempenho de soluções que já foram identificadas como bem-sucedidas.

Em muitos casos, o desafio reside em encontrar o equilíbrio certo entre essas duas estratégias. Abordagens excessivamente exploratórias podem resultar em uma busca ineficiente, enquanto uma ênfase excessiva no aproveitamento pode levar à estagnação em mínimos locais, impedindo a descoberta de soluções globalmente ótimas.

Algoritmos de otimização eficazes conseguem gerenciar essa tensão, adaptando dinamicamente a proporção de exploração e aproveitamento com base no progresso da otimização. Essa abordagem flexível permite que o algoritmo se ajuste a diferentes características do problema, proporcionando um desempenho mais robusto em uma variedade de cenários.

BALANCEAMENTO ENTRE EXPLORAÇÃO E APROVEITAMENTO NO NEAT

No contexto do NEAT (NeuroEvolution of Augmenting Topologies), esse equilíbrio entre exploração e aproveitamento é crucial para o sucesso do algoritmo na evolução de redes neurais. Aqui estão algumas maneiras pelas quais o NEAT lida com esse tradeoff:

Crossover Estrutural Controlado: o NEAT permite a introdução de novas conexões e neurônios (exploração) por meio do crossover estrutural. No entanto, esse

processo é controlado, evitando mudanças drásticas que possam comprometer a estabilidade da população.

Mutação de Adição e Remoção: a mutação de adição de conexão e de adição de neurônio introduz novas possibilidades na rede, promovendo a exploração. Enquanto isso, a mutação de remoção controla a complexidade, evitando que a população se torne excessivamente diversificada.

Fitness Compartilhado: o NEAT utiliza o conceito de fitness compartilhado, onde o desempenho de uma solução é avaliado não apenas em termos absolutos, mas também considerando o desempenho relativo às outras soluções na população. Isso ajuda a evitar que uma solução extremamente boa monopolize o processo evolutivo, equilibrando melhor a exploração e o aproveitamento.

Inovação e Estagnação: o NEAT mantém um registro de inovações na população, recompensando soluções que introduzem novidades. Isso estimula a exploração, enquanto o combate à estagnação evita que a população fique presa em soluções subótimas.

Ao incorporar esses mecanismos, o NEAT consegue equilibrar efetivamente a exploração, introduzindo diversidade e inovação, com o aproveitamento, consolidando e refinando soluções promissoras. Essa abordagem contribui para a capacidade do NEAT em encontrar soluções eficientes e adaptativas em tarefas complexas e dinâmicas.

CASOS DE USO E APLICAÇÕES PRÁTICAS

"Evolving Neural Networks through Augmenting Topologies", de Kenneth O. Stanley e Risto Miikkulainen (2002):

<https://ieeexplore.ieee.org/document/6790655>

O NEAT tem demonstrado seu valor em diversos casos de uso prático. Vamos listar aqui algumas referências interessantes para seu aprofundamento no estudo.

Neste artigo, os autores demonstram a eficácia do NEAT na evolução de topologias de redes neurais para várias tarefas.

AI Learns to Play Super Mario Bros!

Esse exemplo mostra detalhadamente o processo de como a rede “vê” o ambiente do jogo e aprende a jogar empregando NEAT:

Vídeo:

https://www.youtube.com/watch?app=desktop&v=CI3FRsSAa_U&ab_channel=Chrispresso.

Github: <https://github.com/Chrispresso/SuperMarioBros-AI>

["Evolving Deep Convolutional Neural Networks for Image Classification" de Yanan Sun, et al. \(2017\):](#)

Neste trabalho, o NEAT é aplicado para evoluir redes neurais convolucionais profundas para classificação de imagens, destacando sua aplicabilidade na evolução de arquiteturas complexas.

Evolutionary Robotics: The Biology, Intelligence, and Technology of Self-Organizing Machines, Nolfi, S. and Floreano, D. (2000)

Este livro descreve os conceitos básicos e metodologias da robótica evolutiva e os resultados alcançados até agora. Uma característica importante é a apresentação clara de um conjunto de experimentos empíricos de complexidade crescente. Um software com uma interface gráfica, disponível gratuitamente em uma página da web, permitirá que o leitor replique e varie (em simulação e em robôs reais) a maioria dos experimentos.

Unshackling Evolution: Evolving Soft Robots with Multiple Materials and a Powerful Generative Encoding, Nick Cheney, et al, (2013)

Neste trabalho, os corpos de robôs são evoluídos e feitos de vários materiais (músculo, osso e tecido de suporte) para se movimentarem rapidamente. A evolução produz uma variedade diversificada de robôs macios divertidos, excêntricos, interessantes, mas, em última análise, funcionais.

Artigo: http://jeffclune.com/publications/2013_Softbots_GECCO.pdf

Vídeo: <https://www.youtube.com/watch?v=z9ptOeByLA4&t=59s>

Desafios e Considerações

A implementação da NEAT apresenta diversos desafios e considerações que merecem atenção cuidadosa. Alguns destes desafios incluem:

Ajuste de Parâmetros

O NEAT possui diversos parâmetros que influenciam significativamente seu desempenho. Encontrar uma combinação adequada de parâmetros para uma tarefa específica pode ser desafiador, exigindo experimentação e ajuste cuidadoso.

Complexidade Computacional

A evolução de topologias dinâmicas de redes neurais pode ser computacionalmente intensiva, especialmente em cenários complexos. Isso pode limitar a aplicação prática do NEAT em ambientes que demandam eficiência computacional.

Interpretabilidade da Rede

Redes neurais evoluídas pelo NEAT podem tornar-se bastante complexas, dificultando a interpretação dos padrões de aprendizado pela comunidade científica

ou por usuários finais. A interpretabilidade pode ser crucial, especialmente em aplicações críticas.

Convergência para Mínimos Locais

Assim como em outros algoritmos de otimização, o NEAT pode enfrentar o desafio de convergir para mínimos locais em vez de alcançar o ótimo global. Estratégias adicionais podem ser necessárias para evitar a estagnação prematura.

Custos de Treinamento e Avaliação

Treinar e avaliar redes neurais evoluídas pelo NEAT pode exigir recursos computacionais significativos e tempo, especialmente em ambientes de simulação ou com robôs reais. Esses custos devem ser considerados ao implementar o NEAT em larga escala.

Tendências e Desenvolvimentos Futuros

As tendências e desenvolvimentos futuros para a tecnologia Neuro Evolution of Augmenting Topologies (NEAT) apontam para um campo dinâmico e em constante evolução. Algumas direções promissoras incluem:

Integração com Aprendizado Profundo

Espera-se uma maior integração entre NEAT e técnicas de aprendizado profundo. Combinar a flexibilidade de evolução de topologias com as capacidades de representação hierárquica do aprendizado profundo pode resultar em abordagens mais poderosas para a evolução de arquiteturas neurais complexas.

Aplicações em Domínios Específicos

Antecipa-se que o NEAT será aplicado em domínios específicos, como saúde, finanças e robótica, onde a evolução de redes neurais adaptáveis pode fornecer

soluções inovadoras. A customização do NEAT para atender a requisitos específicos de tarefas e ambientes pode impulsionar sua adoção em diversas indústrias.

Melhorias na Eficiência Computacional

Desenvolvimentos futuros podem se concentrar na otimização da eficiência computacional do NEAT, tornando-o mais acessível para implementações práticas em larga escala. Estratégias para reduzir o custo computacional associado ao treinamento e avaliação são áreas potenciais de pesquisa.

Exploração de Múltiplas Tarefas

A capacidade do NEAT de evoluir redes neurais adaptáveis pode ser estendida para a resolução de múltiplas tarefas simultaneamente. A pesquisa pode explorar maneiras de otimizar redes neurais que sejam generalizáveis para uma variedade de contextos, promovendo uma abordagem mais holística.

Exploração de Arquiteturas Híbridas

A combinação de abordagens evolutivas como o NEAT com técnicas de aprendizado profundo e reforço pode levar ao desenvolvimento de arquiteturas híbridas mais eficientes. Essas abordagens podem capitalizar as vantagens de cada técnica, resultando em sistemas mais robustos e adaptáveis.

À medida que a pesquisa continua, é provável que surjam novas ideias e abordagens que expandirão ainda mais o potencial do NEAT e o seu impacto nas aplicações práticas em inteligência artificial e aprendizado de máquina.

O QUE VOCÊ VIU NESTA AULA?

Na segunda aula do nosso curso sobre Algoritmos Genéticos, exploramos a fascinante conexão entre a tecnologia e a inspiração na natureza. Ao abordar algoritmos fundamentados em fenômenos naturais, como redes neurais e colônias de formigas, direcionamos nosso foco para o coração dessa discussão: o algoritmo genético. Descortinamos os princípios dessa abordagem, profundamente enraizada na teoria da evolução, ao examinar a adaptação do mais apto, ilustrando-a com exemplos concretos.

Compreendemos o funcionamento do algoritmo genético por meio de um paralelo entre a evolução na natureza e sua replicação em regras algorítmicas, apresentando um diagrama esclarecedor. Além disso, exploramos o histórico e a evolução dessa área, destacando avanços significativos ao longo do tempo e sua aplicação em problemas do mundo real.

Ao encerrar esta aula, consolidamos nosso entendimento sobre como os Algoritmos Genéticos, ao se inspirarem na natureza, desempenham um papel crucial em diversas aplicações, desde a resolução de problemas práticos até o avanço no treinamento de Redes Neurais.

Na próxima aula, dedicaremos nosso tempo à minuciosa exploração de cada uma das etapas fundamentais que compõem o algoritmo genético. Desde a crucial fase de codificação até a determinação da função de aptidão, passando pelas técnicas de seleção, cruzamento e mutação, examinaremos detalhadamente cada componente. Este enfoque detalhado permitirá uma compreensão abrangente do funcionamento interno do algoritmo genético, destacando a importância de cada etapa no processo global.

Gostaríamos de saber sua opinião sobre o conteúdo! Compartilhe seus comentários e dúvidas no Discord, onde estamos disponíveis na comunidade para responder a perguntas, promover networking, fornecer avisos e muito mais. Junte-se a nós!

REFERÊNCIAS

AI learns to play Super Mario Bros! **YouTube – Chrispresso**. 2020. Disponível em: https://www.youtube.com/watch?app=desktop&v=CI3FRsSAa_U&ab_channel=Chrispresso. Acesso em: 25 mar. 2024.

CHENEY, N.; MACCURDY, R.; CLUNE, J.; LIPSON, H. **Unshackling Evolution: Envolving Soft Robots with Multiple Materials and a Powerful Generative Encoding**. Cornell University. [s.d]. Disponível em: http://jeffclune.com/publications/2013_Softbots_GECCO.pdf. Acesso em: 25 mar. 2024.

POLIMANTE, S.; PRATI, R.; KLEINSCHMIDT, J.H. **Evolução multiobjetivo de trajetórias como múltiplas curvas de Bézier para VANTs**. 2020. [s.l.]. Disponível em: https://www.researchgate.net/publication/376134695_Evolucao_multiobjetivo_de_trajetorias_como_multiplas_curvas_de_Bezier_para_VANTs. Acesso em: 25 mar. 2024.

POLIMANTE, S.; PRATI, R.; KLEINSCHMIDT, J.H. **Otimização Multiobjetivo de Trajetórias de VANTs Utilizando Curvas de Bézier e Algoritmos Genéticos**. Conference XIV Brazilian Congress of Computational Intelligence, Belém, 2019. Disponível em: https://www.researchgate.net/publication/337051141_Otimizacao_Multiobjetivo_de_Trajetorias_de_VANTs_Utilizando_Curvas_de_Bezier_e_Algoritmos_Geneticos. Acesso em: 25 mar. 2024.

STANLEY, O. K.; MIIKULAINEN, R.; et.al. **Envolving Neural Networks through Augmenting Topologies**. IEEE Explore – MIT Press. 2002. Disponível em: <https://ieeexplore.ieee.org/document/6790655>. Acesso em: 25 mar. 2024.

SUN, Y.; XUE, B.; ZHANG, M. YEN, G.G. **Envolving Deep Convolutional Neural Networks for Image Classification**. Cornell University. 2017. Disponível em: <https://arxiv.org/abs/1710.10741>. Acesso em: 25 mar. 2024.

TANGHE, K. B. **On the origin of species: the story of Darwin's title**. The Royal Society Journal of the History of Science. 2018. Disponível em: <https://royalsocietypublishing.org/doi/10.1098/rsnr.2018.0015>. Acesso em: 25 mar. 2024.

PALAVRAS-CHAVE

Genetic Algorithms. Neural Networks. Neuroevolution.

EMAP



POSTECH